


引言




非线性方程求根

问题：非线性方程求根 $f(x) = 0$

方法	二分法	- 二分法原理：对有根区间 $[a, b]$ 二分得到区间套 - 二分法算法：$f(x)=0$ $[a, b]$ $x^* - x^{(k)} < 10^{-3}$ - 二分法误差估计：$x_k - x^* \leq \frac{b-a}{2^{k+1}}$	
	不动点迭代法	- 迭代法原理：$f(x) = 0 \Leftrightarrow x = \phi(x) \xrightarrow{\text{给定 } x_0} x_{k+1} = \phi(x_k)$ - 解的存在唯一性的充分条件 - 迭代法收敛性 - 全局收敛定理：需要同时验证两个条件 - 局部收敛定理：仅验证迭代函数的导函数在精确解处的导数值 $\phi'(x^*) < 1$ - 迭代法的收敛速度 - 收敛速度的定义：$\lim_{k \rightarrow \infty} \frac{x_{k+1} - x^*}{(x_k - x^*)^p} = c \neq 0, p$ 阶收敛 p 阶收敛速度定理：$\phi'(x^*) = \dots = \phi^{(p-1)}(x^*) = 0, \phi^{(p)}(x^*) \neq 0$ - 埃特金加速方法：$\bar{x}_{k+1} = x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} + x_k}$	$x \in [a, b], \phi(x) \in [a, b]$ $\max_{a \leq x \leq b} \phi'(x) < 1$
	Newton 迭代法	- 牛顿迭代法原理：线性化非线性方程 - 牛顿迭代格式：$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$ - 牛顿法的几何意义：切线法 - 牛顿迭代收敛性 - 全局收敛定理 - 局部收敛定理 - 重根的牛顿迭代法 - 已知根的重数 $m, x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}$ - 重数未知：重根变单根，再用牛顿迭代 - 迭代法的收敛速度：平方收敛 (单根)	$\phi(x) = x - \frac{f(x)}{f'(x)}$ $ \phi'(x^*) = 0$ $\mu(x) = \frac{f(x)}{f'(x)}$
	弦截法	- 弦截法原理：用割线斜率代替牛顿法中的导数 - 弦截法迭代格式 - 双点：$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k)$ - 单点：$x_{k+1} = x_k - \frac{x_k - x_0}{f(x_k) - f(x_0)} f(x_k)$ - 弦截法的几何意义：割线法的类型及收敛性 - 双点弦截法 - 单点弦截法 - 双点弦截法的收敛速度：$p = 1.618$	$f'(x_k)$ 复杂 $f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$

求解线性代数方程组的直接法



求解线性代数方程组的迭代法

问题：求解线性代数方程 $Ax = b$

分量形式

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}}(b - a_{12}x_2^{(k)} - \dots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}}(b - a_{21}x_1^{(k+1)} - \dots - a_{2n}x_n^{(k)}) \end{cases}$$

$$A = \begin{pmatrix} 1 & 6 & 1 \\ 11 & 2 & 2 \\ 3 & 2 & 9 \end{pmatrix} Ax = b$$

$$A \xrightarrow{r_1 \leftrightarrow r_2} \begin{pmatrix} 11 & 2 & 2 \\ 1 & 6 & 1 \\ 3 & 2 & 9 \end{pmatrix}$$

$$Bx = \tilde{b}$$

迭代法 ($A = D - L - U$)

Jacobi 迭代法



$$\text{迭代算法: } x^{k+1} = D^{-1}(L + U)x^k + D^{-1}b; B_J = D^{-1}(L + U)$$

算法收敛性

- 充要条件：迭代法收敛 $\Leftrightarrow \rho(B_J) < 1$
- 充分条件：若 $\|B_J\| < 1 \Rightarrow$ 迭代法收敛
- 若系数矩阵是严格对角占有 $\Rightarrow$ 迭代法收敛

A 对称, $\forall i, a_{ii} > 0$, Jacobi 迭代收敛 $\Leftrightarrow D, 2D - A$ 正定

Gauss-Seidel 迭代法



$$\text{迭代算法: } x^{k+1} = (D - L)^{-1}Ux^k + (D - L)^{-1}b; B_G = (D - L)^{-1}U$$

算法收敛性

- 充要条件：迭代法收敛 $\Leftrightarrow \rho(B_G) < 1$
- 充分条件：若 $\|B_G\| < 1 \Rightarrow$ 迭代法收敛
- 若系数矩阵是严格对角占有 $\Rightarrow$ 迭代法收敛
- A 对称正定 $\Rightarrow$ Gauss Seidel 迭代法收敛

$$|I - B_G| = 0$$

$$|\lambda(D - L) - U| = 0$$

超松弛迭代法

$$\text{迭代算法: } x^{k+1} = (D - \omega L)^{-1}((1 - \omega)D + \omega U)x^k + \omega(D - \omega L)^{-1}b;$$

算法收敛性

- 充要条件：迭代法收敛 $\Leftrightarrow \rho(B_S) < 1$
- 充分条件：若 $\|B_S\| < 1 \Rightarrow$ 迭代法收敛
- 必要条件：迭代法收敛 $\Rightarrow 0 < \omega < 2$
- 若系数矩阵是严格对角占有且 $0 < \omega \leq 1 \Rightarrow$ 迭代法收敛
- A 对称正定且 $0 < \omega < 2 \Rightarrow$ 迭代法收敛

收敛速度 $R(B) = -\ln \rho(B)$

插值法

问题1：已知函数在若干不同节点上 $\{x_j\}_{j=0}^n$ 的函数值 $\{y_j\}_{j=0}^n$ ，如何求该组节点的逼近多项式

问题2：已知函数在若干不同节点上 $\{x_j\}_{j=0}^n$ 的函数值 $\{y_j\}_{j=0}^n$ 及导数值 $\{m_j\}_{j=0}^n$ ，如何求该组节点的逼近多项式

基于幂级数 $\{1, x, \dots, x^n\}$

$P_n(x) = a_0 + a_1x + \dots + a_nx^n,$

系数满足 $\begin{pmatrix} 1 & x_0 & \dots & x_0^n \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & \dots & x_n^n \end{pmatrix} \begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ \vdots \\ y_n \end{pmatrix}$

系数矩阵行列式是范德蒙德行列式，得出插值多项式是唯一的

Lagrange插值法

Lagrange基函数

基函数形式 $\{l_j(x)\}_{j=0}^n$

基函数性质 $\begin{cases} l_j(x_i) = \delta_{ij} \\ \sum_{j=0}^n l_j(x) = 1 \\ x^k = \sum_{j=0}^n x_j^k l_j(x), \quad 0 \leq k \leq n \end{cases}$

Lagrange插值多项式: $L_n(x) = \sum_{j=0}^n y_j l_j(x)$

Lagrange插值余项: $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = \prod_{k=0}^n (x - x_k).$

均差和Newton插值

均差及其性质

均差定义：一阶均差，二阶均差等

均差的性质：4条性质

n次多项式的k阶均差为一个n-k次多项式

均差与导数的关系

.....

均差表：利用均差表求Newton插值多项式

牛顿插值多项式 $N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n] \prod_{i=0}^{n-1} (x - x_i)$

差分及等距节点的差分公式

三次Hermite插值

三次Hermite插值多项式

三次Hermite插值基函数

三次Hermite插值: $H_3(x) = y_0 \alpha_0(x) + y_1 \alpha_1(x) + m_0 \beta_0(x) + m_1 \beta_1(x).$

误差估计: $|f(x) - H_3(x)| = \left| \frac{f^{(4)}(\xi)}{4!} \right| (x - x_0)^2 (x - x_1)^2 \leq C \frac{1}{384} |f^{(4)}(\xi)| h^4 \quad (h = |x_1 - x_0|)$

分段低次插值多项式

分段线性插值：插值公式；分段线性插值的误差,根据误差确定区间长度

分段三次Hermite插值：插值公式;分段三次Hermite插值误差,根据误差确定步长

三次样条插值

问题的提出:确定n+1个剖分点的样条需要4n个条件，而问题仅给出了4n-2个条件

三弯矩方程:未知量 $\{M_i = S''(x_i)\}_{i=0}^n$ 为弯矩

三转角方程:未知量 $\{m_i = S'(x_i)\}_{i=0}^n$ 为转角

$f[x_0, x_1] = f'(x_0)$

二次连续可导


$f(x) = \begin{cases} 1+2x+3x^2 & x \in [0, 1] \\ 5x+6 & x \in [1, 2] \end{cases}$

$x \in [2, 3]$

5

曲线拟合

问题：已知函数 $f(x) \in A$, 求简单函数 $p(x) \in B$, 使得 $f(x) - p(x)$ 在某种度量下最小	
基础知识	基本概念 函数逼近与函数空间 ★ <u>范数与赋范线性空间: 函数的 $\ \cdot\ _1, \ \cdot\ _2, \ \cdot\ _\infty$ 计算</u> 内积与内积空间: 内积定义, 性质 正交多项式 正交函数族和正交多项式族 ★ Legendre 正交多项式 ★ Chebyshev 正交多项式
最佳平方逼近 ★	问题：已知 $f(x) \in C[a, b]$, 求 $s(x) \in \text{span}\{\phi_0(x), \dots, \phi_n(x)\}$, $s.t. \ f(x) - s(x)\ _2$ 最小. ★ 求解: $s(x) = \sum_{j=0}^n a_j \phi_j(x)$, $\{a_j\}_{j=0}^n$ 满足 $\begin{pmatrix} (\phi_0, \phi_0) & \cdots & (\phi_n(x), \phi_0(x)) \\ \vdots & \ddots & \vdots \\ (\phi_n, \phi_0) & \cdots & (\phi_n(x), \phi_n(x)) \end{pmatrix} \begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (f(x), \phi_0(x)) \\ \vdots \\ (f(x), \phi_n(x)) \end{pmatrix}$ $(\phi_i, \phi_j) = \int_a^b \phi_i(x) \phi_j(x) dx; (f, \phi_i) = \int_a^b f(x) \phi_i(x) dx$ 误差: $\ f - s\ _2^2 = \ f\ _2^2 - \sum_{j=0}^n a_j (f, \phi_j)$. 正交函数基底: $s = \sum_{j=0}^n \frac{(f, \phi_j)}{\ \phi_j\ _2^2} \phi_j(x)$; 误差为 $\left(\ f\ _2^2 - \sum_{j=0}^n \frac{(f, \phi_j)^2}{\ \phi_j\ _2^2} \right)^{\frac{1}{2}}$
拟合的最小二乘法 ★	问题：已知若干实验数据点 $\{(x_j, y_j)\}_{j=0}^m$, 求该组节点的拟合函数 $s(x) \in \{\phi_0(x), \dots, \phi_n(x), (n < m)\}$. $s(x) = a_0 \phi_0 + a_1 \phi_1 + \dots + a_n \phi_n$, $\begin{pmatrix} (\phi_0, \phi_0) & \cdots & (\phi_n(x), \phi_0(x)) \\ \vdots & \ddots & \vdots \\ (\phi_n, \phi_0) & \cdots & (\phi_n(x), \phi_n(x)) \end{pmatrix} \begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (y, \phi_0(x)) \\ \vdots \\ (y, \phi_n(x)) \end{pmatrix}$ $(\phi_i, \phi_j) = \sum_{k=0}^m \phi_i(x_k) \phi_j(x_k); (f, \phi_i) = \sum_{k=0}^m f(x_k) \phi_i(x_k)$ 可转换成线性模型的最小二乘法 $y = ae^{bx} \rightarrow \ln y = \ln a + bx \rightarrow u = A + Bx$
最佳一致逼近	问题: 已知 $f \in C[a, b]$, 求多项式 $p(x)$, $s.t. \ f - p\ _\infty$ 最小. ★ 可求问题: $\begin{cases} \text{求 } \mathcal{P}_n \text{ 的 } \mathcal{P}_{n-1} \text{ 最佳一致逼近 } \star \\ f \in C^2[a, b], f'' \text{ 保号, 求其线性最佳一致逼近函数.} \end{cases}$



常微分方程的初值问题: $\begin{cases} y' = f(x, y), (a \leq x \leq b, y < \infty) \\ y(a) = y_0. \end{cases}$	
引言:	当方程中$f(x, y)$连续且关于y满足Lipschitz 函数时,方程存在唯一解。 初值对解的影响:$y_1 - y_2 \leq e^{L(x-a)} s_1 - s_2$ 解析解法得到满足方程的函数, 数值解法得到一系列点上的函数值
	简单数值方法
	欧拉法:$y_{n+1} = y_n + hf(x_n, y_n)$ 后退欧拉法:$y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$ 梯形方法:$y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$ 改进欧拉法: $\begin{cases} \bar{y}_{n+1} = y_n + hf(x_n, y_n) \\ y_{n+1} = \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})] \end{cases}$ $\leftarrow$ 2阶 R-K方法 局部截断误差与阶 $\begin{cases} \text{定义: } T_{n+1} = y(x_{n+1}) - y(x_n) - h\phi(x_n, y(x_n), h) = \mathcal{O}(h^{p+1}) \\ \text{为具有p阶精度的方法} \\ \text{简单方法的局部截断误差} \begin{cases} \text{欧拉法: } \mathcal{O}(h^2) \\ \text{梯形方法: } \mathcal{O}(h^3). \end{cases} \end{cases}$
	龙格-库塔方法
单步法的收敛与稳定性	显式R-K的一般形式 $\begin{cases} \text{原理:提高积分 } \int_{x_n}^{x_{n+1}} f(x, y)dx \text{ 的精度} \\ \text{一般形式: } y_{n+1} = y_n + h\phi(x_n, y_n, h), \phi_n(x_n, y_n, h) = \sum_{i=1}^r c_i K_i, \\ K_1 = f(x_n, y_n), K_i = f(x_n + \lambda_i h, y_n + h \sum_{j=1}^{i-1} \mu_{ij} K_j), i = 2, 3, \dots \end{cases}$ 二阶显式R-K方法 $\begin{cases} \text{一般式: } y_{n+1} = y_n + (c_1 K_1 + c_2 K_2), K_1 = f(x_n, y_n), \\ K_2 = f(x_n + \lambda_2 h, y_n + \mu_{21} h K_1); c_1 + c_2 = 1; c_2 \lambda_2 = \frac{1}{2}; c_2 \mu_{21} = \frac{1}{2} \end{cases}$ 三、四阶显式R-K方法 $\begin{cases} \text{三阶方法: } y_{n+1} = y_n + (c_1 K_1 + c_2 K_2 + c_3 K_3); \\ \text{四阶方法: } y_{n+1} = y_n + (c_1 K_1 + c_2 K_2 + c_3 K_3 + c_4 K_4); \end{cases}$ 定义:$h \rightarrow 0, y_n \rightarrow y(x_n)$ 收敛定理:单步法具有p阶精度, 函数$\phi(x, y, h)$关于y 满足Lipschitz 条件 当初值误差为0时, $y(x_n) - y_n = \mathcal{O}(h^p)$ 若$\phi(x, y, 0) = f(x, y)$, 称单步法与初值问题相容, p阶方法与初值问题相容 $\Leftrightarrow p \geq 1$
	绝对稳定性, 绝对稳定域
	(1)影响稳定性的因素:方法,步长h, 及$f(x, y)$ (2)考察数值方法本身, 仅考虑模型问题$y' = \lambda y$ (3)$y_{n+1} = E(h\lambda)y_n$, 满足$E(h\lambda) < 1$为稳定方法, 使得$E(h\lambda) < 1$围成的区域为绝对稳定域 (4)显式Euler: $-2 < \lambda h < 0, \dots$
	线性多步法
多步法的一般公式及算法思想 阿当姆斯(Adams)显式与隐式公式	

矩阵特征值的计算

特征值的性质和估计	特征值问题及性质 $R(x) = \frac{(Ax, x)}{(x, x)} \Rightarrow \begin{cases} \lambda_n \leq R(x) \leq \lambda_1 \\ \lambda_1 = \max_{x \neq 0} R(x), \lambda_n = \min_{x \neq 0} R(x). \end{cases}$ 特征值估计:圆盘定理 $\begin{cases} A \in \mathbb{R}^{n \times n}, A \text{ 的每个特征值必属于下述的某个圆盘之中} \\ \lambda - a_{ii} \leq r_i = \sum_{j=1, j \neq i}^n a_{ij} , i = 1, 2, \dots, n \end{cases}$
	算法: $A_{n \times n}$ 有 n 个线性无关的特征向量且 $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n, Ax_1 = \lambda_1 x_1$. (1)算法1: $v_0 \neq 0, v_1 = Av_0, \dots, v_k = Av_{k-1}, \dots$ (2)算法2: $v_0 = u_0 \neq 0, v_1 = Au_0; u_1 = \frac{v_1}{\max\{v_1\}}; \dots, v_k = Au_{k-1}, u_k = \frac{v_k}{\max\{v_k\}}, \dots,$ 定理 $\begin{cases} \text{算法1: } \lim_{k \rightarrow \infty} \frac{v_k}{\lambda_1^k} = a_1 x_1 (a_1 \neq 0), \lim_{k \rightarrow \infty} \frac{(v_{k+1})_j}{(v_k)_j} = \lambda_1. \\ \text{算法2: } \lim_{k \rightarrow \infty} \max v_k = \lambda_1, \lim_{k \rightarrow \infty} u_k = \frac{x_1}{\max\{x_1\}} \end{cases}$ 幂法加速 $\begin{cases} \text{原点位移法} \\ \text{Rayleigh商加速} \end{cases}$ 反幂法: (1)若 A 可逆且 A 有 n 个线性无关的特征向量且 $\lambda_1 \geq \dots \geq \lambda_{n-1} > \lambda_n, Ax_n = \lambda_n x_n$. (2)对 A^{-1} 利用幂法可以求出 A 的最小特征值和特征向量。 (3)原点位移加速方法